



Politechnika Warszawska

Wydział Matematyki
i Nauk Informatycznych

Praca dyplomowa licencjacka

na kierunku Matematyka i analiza danych

Wyjaśnialne modele uczenia maszynowego w prognozowaniu rynków
finansowych z wykorzystaniem informacji zawartych w komunikatach
giełdowych

Wiktor Chmiel

Numer albumu 333045

promotor

dr Robert Małysz

WARSZAWA 2026

Streszczenie

Wyjaśnialne modele uczenia maszynowego w prognozowaniu rynków finansowych z wykorzystaniem informacji zawartych w komunikatach giełdowych

TU będzie streszczenie później

Słowa kluczowe: słowo klucz 1, słowo klucz 2, ...

Abstract

Explainable Machine Learning Models in Financial Market Forecasting Using
Information Contained in Stock Exchange Announcements

This will be made later

Keywords: keyword1, keyword2, ...

Spis treści

1. Wstęp	11
Wstęp	11
2. ML - informacje wstępne	12
2.1. Ogólne pojęcia	12
2.2. Miary oceny modeli	13
2.2.1. Problem regresji	14
2.2.2. Problem klasyfikacji	15
2.3. Modele ML	17
2.3.1. Regresja logistyczna	18
3. Dane	20
4. Implementacja	21
5. XAI	22
6. Aplikacja	23
7. Podsumowanie	24

1. Wstęp

O czym jest praca? Co się w niej znajduje? Jaki jest wkład autora?

UWAGA! W pracy dyplomowej zespołowej: opis podziału prac obejmujący zakres wkładu każdego ze współautorów w część praktyczną (zespołowy projekt programistyczny) oraz część opisową pracy.

2. ML - informacje wstępne

Zanim zaczniemy, przypomnijmy podstawowe pojęcia związane z działem uczenia maszynowego.

Założmy, że dysponujemy danymi $\mathcal{D}$ w postaci ramki danych zawierającej zarówno kolumny numeryczne (np. wiek 67) jak i katagoryczne (np. opis produktu w postaci litery A, B, C).

Zazwyczaj dane $\mathcal{D}$ można podzielić na dwie grupy:

$$\mathcal{D} = (X, Y) = \{(x_i, y_i)\}_{i=1}^n$$

przy czym X to dane, którymi zawsze dysponujemy, nazywane predytorami/zmiennymi objaśniającymi natomiast Y to wektor wynikowy, którym nie zawsze dysponujemy. Y można też nazywać zmienną objaśnialną/wynikową. Dodatkowo każda pojedyncza obserwacja należy do przestrzeni cech:

$$\forall i \in [n] \ x_i \in \mathcal{X}$$

a każda wartość zmiennej objaśnialnej należy do przestrzeni wartości wynikowych:

$$\forall i \in [n] \ y_i \in \mathcal{Y}$$

2.1. Ogólne pojęcia

Definicja 2.1 (Główne rodzaje uczenia maszynowego). Uczenie maszynowe można podzielić na wiele kategorii. Oto najważniejsze z nich:

- uczenie nadzorowane (ang. supervised learning), czyli takie gdzie mamy wektor wynikowy i zadanie to stworzenie modelu prognozującego wartości. W tym przypadku znamy wektor Y .
- uczenie nienadzorowane (ang. unsupervised learning), czyli takie gdzie nie mamy zmiennej objaśnialnej i zadanie polega na pogrupowaniu danych w odpowiednie klastry. Tutaj nie mamy wektora Y .

2.2. MIARY OCENY MODELI

- uczenie półnadzorowane (ang. semi-supervised learning), czyli sytuacja gdzie część danych ma wartość zmiennej objaśnialnej, a część nie.

Definicja 2.2 (Regresja i klasyfikacja). W zależności od tego jak problem jest zdefiniowany, zadanie możemy podzielić na:

- problem regresji, gdy zmienna objaśnialna Y przyjmuje wartości rzeczywiste ($Y \in \mathbb{R}^n$)
- problem klasyfikacji, gdy zmienna wynikowa Y przyjmuje skończoną liczbę wartości, czyli zbiór etykiet wtedy można zapisać jako:

$$\mathcal{Y} = \{c_1, \dots, c_k\}$$

Szczegółym przypadkiem jest gdy $|\mathcal{Y}| = 2$ (najczęściej $\mathcal{Y} = \{0, 1\}$). Wtedy taki problem nazywamy klasyfikacją binarną.

Zanim przejdziemy do samych modeli, warto wspomnieć jeszcze o podziale naszych danych na 3 zbiory oraz o walidacji krzyżowej.


Dzielimy dane $\mathcal{D}$ na 3 zbiory:

1. uczący, na którym nasz model będzie trenowany,
2. walidacyjny, na którym model jest "dostrajany" (dobierane są odpowiednie hiperparametry modeli),
3. testowy, na którym model jest poddawany ostatecznej ewaluacji.

Definicja 2.3 (Walidacja krzyżowa / kroswalidacja, ang. k -fold CV). Zakładamy, że dysponujemy zbiorem danych $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n$ oraz dowolnym modelem M . Kroswalidacja to metoda dzielenia zbioru na k rozłącznych części (ang. folds), tak aby ich suma stanowiła całe dostępne dane $\mathcal{D}$. Następnie w pętli iterującej k razy, w każdym kroku inna część danych jest używana do walidacji modelu, a model jest trenowany na pozostałych $k - 1$ częściach. Proces ten dla $k = 5$ zilustrowano na Rysunku 2.1.

2.2. Miary oceny modeli

W zależności od rodzaju problemu, regresja czy klasyfikacja, możemy dobrać różne miary mające pomóc nam ocenić jak dobrze poradził sobie nasz model.



Rysunek 2.1: Schemat działania 5-krotnej walidacji krzyżowej (5-fold CV).

2.2.1. Problem regresji

Założmy, że mamy do czynienia z problemem regresji z danymi $\mathcal{D}$ oraz modelem $M : \mathcal{X} \rightarrow \mathbb{R}$. Najpopularniejszą miarą służącą do oceny takiego modelu jest błąd średniokwadratowy (and. mean square error)

Definicja 2.4 (błąd średniokwadratowy (MSE)). Założmy, że mamy próbkę $\mathbb{X}$ oraz estymator $\hat{\theta}(\mathbb{X})$ parametru θ . Błąd średniokwadratowy tego estymatora wyraża się jako

$$MSE(\hat{\theta}(\mathbb{X})) = \mathbb{E}[(\hat{\theta}(\mathbb{X}) - \theta)^2]$$

W ML jednak, nie znamy prawdziwego rozkładu, więc korzystamy z empirycznego odpowiednika. Jako estymator traktujemy predykcję modelu $\hat{y}_i = M(x_i)$, a jako rzeczywistą wartość przyjmuje się y_i . Empiryczny odpowiednik MSE wyraża się jako:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Korzysta się tutaj z faktu, że nieobciążonym estymatorem wartości oczekiwanej jest średnia (co wynika z MPWL).

Definicja 2.5 (Rezyduum). Mając dane $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n$ oraz model M można zdefiniować rezyduum i -tej obserwacji x_i jako różnicę między wartością prawdziwą, a przewidzianą przez

2.2. MIARY OCENY MODELI

model $M(x_i) = \hat{y}_i$:

$$e_i = y_i - \hat{y}_i$$

Cały wektor takich wartości nazywamy wektorem rezyduów:

$$e = \begin{pmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{pmatrix} = Y - \hat{Y}$$

przy czym $Y = (y_1, \dots, y_n)^T$, $\hat{Y} = (M(x_1), \dots, M(x_n))$

Stwierdzenie 2.6. Przy pomocy wektora rezyduów można wyrazić MSE jako:

$$MSE = \frac{1}{n} e^T e$$

2.2.2. Problem klasyfikacji

Sytuacja wygląda inaczej, gdy mamy do czynienia z problemem klasyfikacji. Poniżej zostaną omówione różne miary dla klasyfikacji binarnej (właśnie tą będę się zajmował)

Definicja 2.7 (Macierz pomyłek (ang. Confusion matrix)). Mając dane $\mathcal{D}$ oraz model M możemy zdefiniować 4 pomocnicze wartości zliczające:

- **True Positive (TP):** Model przewidział wartość "pozytywną" i była to prawda, czyli w rzeczywistości wartość też jest "pozytywna"
- **True Negative (TN):** Model przewidział wartość "negatywną" i była to prawda
- **False Positive (FP):** Model przewidział wartość "pozytywną", ale to była pomyłka, czyli w rzeczywistości wartość też jest "negatywna"
- **False Negative (FN):** Model przewidział wartość "negatywną", ale to była pomyłka, czyli w rzeczywistości wartość też jest "pozytywna"

Macierz pomyłek to kwadratowa macierz, która wygląda następująco:

$$\begin{pmatrix} TP & FN \\ FP & TN \end{pmatrix}$$

Zgodnie z przyjętą konwencją kolumny macierzy pomyłek odpowiadają wartością przewidzianym przez model, a wiersze przedstawiają wartości rzeczywiste. Ilustruje to rysunek 2.2

		Predicted Values	
		Positive	Negative
Actual Values	Positive	TP	FN
	Negative	FP	TN

Rysunek 2.2: Macierz pomyłek dla problemu klasyfikacji binarnej

W praktyce chcemy aby macierz pomyłek "była jak najbliższej" macierzy diagonalnej, czyli aby miała wartości dodatnie na samej diagonalu.

Dalej możemy zdefiniować kluczowe dla dalszej oceny miary modelu:

Definicja 2.8 (Dokładność (ang. accuracy)). Przy założeniach jak w poprzednich definicjach możemy zdefiniować podstawową miarę:

$$Accuracy = \frac{TP + TN}{TP + TN + FN + FP}$$

Jest to miara mówiąca o tym jaki procent poprawnych przypadków wykrył dany model

Jest to najbardziej intuicyjna miara, ale ma jednak ona swoje wady, co ilustruje poniższy przykład

Przykład 2.9. Załóżmy, że interesuje nas problem klasyfikacji binarnej pacjentów zdrowych (0) oraz pacjentów chorych (1), mamy dane $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^{1000}$, przy czym:

$$\forall i \in [933] \ y_i = 0, \forall j \in \{934, \dots, 1000\} \ y_j = 1$$

Stworzony model M przewiduje, niezależnie od danych, że pacjent jest zawsze zdrowy (0). Wówczas otrzymujemy:

$$TP = 0, TN = 933, FP = 0, FN = 67$$

2.3. MODELE ML

Zatem dokładność jest równa:

$$Accuracy = \frac{933}{1000} = 93,3\%$$

Jest to teoretycznie wartość bardzo wysoka, jednakże taki model jest poprostu bezużyteczny

Zatem sama miara dokładności nie wystarczy do oceny tego czy model jest dobry. Potrzebne są do tego inne narzędzia

Definicja 2.10 (Czułość (ang. Recall)). Zakładamy, że występują te same założenia co we wcześniejszych definicjach. Czułość definiujemy jako:

$$Recall = \frac{TP}{TP + FN}$$

Ta miara informuje o tym jaki procent wartości rzeczywiście "pozytywnych" model zdołał przewidzieć poprawnie.

Definicja 2.11 (Precyzja (ang. Precision)). Przy tych samych założeniach co wcześniej, precyzję definiuje się jako:

$$Precision = \frac{TP}{TP + FP}$$

Precyzja informuje o tym jaki procent wartości przewidzianych "pozytywnych" jest poprawnie dopasowanych.

Definicja 2.12 (Swoistość (ang. Specifity)). Zakładając te same założenia co poprzednio, swoistość definiujemy jako

$$Specifity = \frac{TN}{TN + FP}$$

Miara ta informuje jaki procent rzeczywistych "negatywnych" wartości model zdołał przewidzieć.

Definicja 2.13 (F_1 score). Przy tych samych założeniach, jest to średnia harmoniczna między precyzją, a czułością:

$$F_1 = \frac{2}{\frac{1}{Precision} + \frac{1}{Recall}} = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

W mojej pracy będę się skupiał na maksymalizacji f_1 lub precyzji

2.3. Modele ML

W tym podrozdziale zostaną omówione 3 algorytmy ML, które zostaną wykorzystane w mojej pracy. Wszystkie są algorytmami do pracy z problemem klasyfikacji binarnej. Jeden to będzie

model typu white-box, a pozostałe dwa będą modelami typu "black-box"

2.3.1. Regresja logistyczna

Jest to najprostszy z omawianych tutaj modeli ML. Jest to algorytm typu "white-box", czyli jest interpretowalny ze względu na jego budowę (model-design). Regresja logistyczna to szczególny przypadek uogólnionego modelu liniowego (ang. GLM).

Definicja 2.14 (GLM). Jest to model, który jest opisywany za pomocą trzech komponentów:

1. Losowy komponent(ang. *Random Component*) - ten warunek opisuje zmienna objaśnialną, czyli $Y = (Y_1, \dots, Y_n)^T$. Każda ze zmiennych losowych Y_i jest niezależną zmienną losową pochodzącą z wykładniczej rodziny (ang. *exponential family*)
2. Liniowy predyktor (ang. *Linear Predictor*):

$$\forall i \in [n] \quad \eta_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}$$

3. Funkcja łącząca (ang. *link function*) - to taka funkcja g , że:

$$\forall i \in [n] \quad g(\mu_i) = \eta_i$$

gdzie $\forall i \in [n] \quad \mu_i = \mathbb{E}[Y_i]$

Zazwyczaj zakłada się, że funkcja g jest różniczkowalna, monotoniczna oraz odwracalna

W przypadku regresji logistycznej funkcja łącząca to funkcja logit $g \equiv \text{logit}$, czyli:

$$g(\mu_i) = \text{logit}(\mu_i) = \ln \left(\frac{\mu_i}{1 - \mu_i} \right)$$

W przypadku regresji logistycznej zmienna objaśnialna Y_i przyjmuje tylko dwie wartości: 0 lub 1. Zatem można zapisać:

$$\pi = \mathbb{P}(Y_i = 1), \quad 1 - \pi = \mathbb{P}(Y_i = 0)$$

Zapisując to razem otrzymujemy

$$\forall y \in \{0, 1\} \quad \mathbb{P}(Y_i = y) = \pi^y (1 - \pi)^{1-y}$$

Czyli zmienna Y_i ma rozkład dwupunktowy (binarny), wówczas:

$$\mu_i = \mathbb{E}[Y_i] = 0 \cdot \mathbb{P}(Y_i = 0) + 1 \cdot \mathbb{P}(Y_i = 1) = \mathbb{P}(Y_i = 1) = \pi$$

Wówczas można zapisać rozkład zmiennej Y_i za pomocą jej momentu:

$$\forall y \in \{0, 1\} \quad \mathbb{P}(Y_i = y) = \mu_i^y \cdot (1 - \mu_i)^{1-y} = \mathbb{P}(y, \mu_i)$$

2.3. MODELE ML

Dodatkowo wariancja zmienn $Y_i \sim \text{Bern}(\pi)$ jest wtedy równa:

$$\text{Var}[Y_i] = \mu_i(1 - \mu_i)$$

3. Dane

4. Implementacja

5. XAI

6. Aplikacja

7. Podsumowanie

Bibliografia

- [1] A. Author, *Title of a book*, Publisher, year, page–page.
- [2] J. Bobkowski, S. Dobkowski, Jak stworzyć bibliografię w BibTeX-u, *Czasopismo nr*, rok, strona–strona.
- [3] C. Brink, Power structures, *Algebra Universalis* 30(2), 1993, 177–216.
- [4] F. Burris, H. P. Sankappanavar, *A Course of Universal Algebra*, Springer-Verlag, Nowy Jork, 1981.

Wykaz symboli i skrótów

ML	Machine Learning
XAI	eXplainable Artificial Intelligence
SHAP	SHapley Addictive exPlanations
LIME	Local Interpretable Model-agnostic Explanations
NLP	Natural Language Processing
PDP	Partial Dependence Plot
PCA	Principal Components Analysis
ALE	Accumulated Local Effects
RF	Random Forest
XGBoost	eXtreme Gradient Boosting
NN	Neural Network
CV	Cross Validation
$\mathbb{P}(A)$	prawdopodobieństwo zdarzenia A
$\mathbb{E}[X]$	wartość oczekiwana zmiennej losowej X
$Var[X]$	wariancja zmiennej losowej X
$Cov[X, Y]$	kowariancja zmiennych losowych X i Y
$\rho(X, Y)$	współczynnik korelacji Pearsona zmiennych losowych X i Y
$\mathbb{N}$	zbiór liczb naturalnych
$\mathbb{Q}$	zbiór liczb wymiernych
$\mathbb{R}$	zbiór liczb rzeczywistych
$\mathbb{C}$	zbiór liczb zespolonych
$\mathbb{R}^n$	zbiór wektorów n -wymiarowych, które mają wszystkie współrzędne rzeczywiste
$[n]$	zbiór liczb od 1 do n , czyli $[n] = \{1, 2, \dots, n\}$
$\mathcal{X}$	przestrzeń cech
$\mathcal{Y}$	przestrzeń wartości wynikowych/oznaczeń (ang. label)
MSE	Mean Square Error
"white-box"	model ML interpretowalny
"black-box"	model ML nieinterpretowalny
GLM	Generalized Linear Model

Spis rysunków

2.1	Schemat działania 5-krotnej walidacji krzyżowej (5-fold CV).	14
2.2	Macierz pomyłek dla problemu klasyfikacji binarnej	16

Spis tabel

Spis załączników

1. Załącznik 1
2. Załącznik 2
3. Jak nie występują, usunąć rozdział.